معالجة اللغات الطبيعية (NLP)

حلول شاملة وكاملة لجميع أسئلة الاختبار مع شرح مفصل

📌 يحتوي هذا المستند على حلول كاملة ومفصلة لجميع الأسئلة 📌

✦ ✦ ✦

القسم الأول: اختيار من متعدد (20 سؤال) 🤔

1. الهدف الأساسي من NLP هو:

- الإجابة: ب) فهم اللغة البشرية

الشرح: يهدف NLP إلى تمكين الحاسوب من فهم وتحليل وتوليد اللغة البشرية.

2. Tokenization تعني:

- الإجابة: ب) تقسيم النص

الشرح: عملية تقسيم النص إلى وحدات أصغر مثل الكلمات أو الجمل.

3. Stop Words هي:

- الإجابة: ب) كلمات شائعة قليلة القيمة

الشرح: كلمات مثل 'من'، 'في'، 'كان' يتم إزالتها لأنها لا تحمل معنى كبيراً.

4. TF-IDF يستخدم لـ:

- الإجابة: ب) تمثيل النص

الشرح: طريقة إحصائية لتحويل النصوص إلى أرقام مع وزن الكلمات المهمة.

5. Bag of Words:

- الإجابة: ب) يهمل الترتيب

الشرح: تمثيل النص كمصفوفة تكرار للكلمات دون مراعاة الترتيب.

6. أي نموذج يعتمد على السياق؟

- الإجابة: ج) BERT

الشرح: نموذج يستخدم السياق ثنائي الاتجاه لفهم معنى الكلمات.

7. Lemmatization

- الإجابة: ب (تحويل الكلمة لأصلها

الشرح: إرجاع الكلمة إلى أصلها المعجمي مثل 'أكلت' → 'أكل'.

8. Word2Vec ينتج

- الإجابة: ب (متجهات

الشرح: تمثيلات رقمية كثيفة للكلمات في فضاء متعدد الأبعاد.

9. أي خوارزمية مناسبة لتصنيف النص؟

- الإجابة: د (جميع ما سبق

الشرح: KNN، Naive Bayes، Decision Tree كلها تستخدم في تصنيف النصوص.

10. NER تعني

- الإجابة: ب (التعرف على الكيانات

الشرح: Named Entity Recognition - تحديد الكيانات مثل الأشخاص والأماكن.

11. Overfitting يعني

- الإجابة: ب (نموذج يحفظ البيانات

الشرح: النموذج يتعلم التفاصيل والضوضاء بدلاً من الأنماط العامة.

12. Underfitting يعني

- الإجابة: أ (نموذج بسيط جداً

الشرح: النموذج لم يتعلم الأنماط الأساسية في البيانات.

13. Embedding هو

- الإجابة: ب (تمثيل رقمي للكلمات

الشرح: تحويل الكلمات إلى متجهات أرقام.

14. Language Model هدفه

- الإجابة: ب (توقع الكلمة التالية

الشرح: حساب احتمالية تسلسل الكلمات والتنبؤ بالكلمة التالية.

15. Transformer يعتمد على

- الإجابة: ج) Attention

الشرح: آلية الانتباه التي تسمح بالتركيز على الكلمات المهمة.

16. Attention يساعد في

- الإجابة: ب (التركيز على الكلمات المهمة

الشرح: تحسين فهم السياق والمعنى في النصوص الطويلة.

17. POS Tagging

- الإجابة: ب (تحديد نوع الكلمة

الشرح: تحديد الفئة النحوية مثل اسم، فعل، صفة.

18. أي مما يلي Unsupervised؟

- الإجابة: ب) Clustering

الشرح: التجميع هو تعلم غير خاضع للإشراف.

19. Cosine Similarity تستخدم لـ

- الإجابة: ب (قياس التشابه

الشرح: قياس درجة التشابه بين متجهين.

20. GPT هو

- الإجابة: أ (نموذج لغة

الشرح: Generative Pre-trained Transformer - نموذج لغة كبير.

القسم الثاني: أسئلة نظرية (15 سؤال) ✍

1. اشرح مفهوم Tokenization مع مثال.

تقسيم) Word Tokenization: هي عملية تقسيم النص إلى وحدات أصغر تسمى توكينات. أنواعها Tokenization: (تقسيم إلى أجزاء. مثال) Subword Tokenization، (تقسيم إلى جمل) Sentence Tokenization، (إلى كلمات
الذكاء الاصطناعي يغير العالم'] → 'الذكاء', 'الاصطناعي', 'يغير', 'العالم''.

2. ما الفرق بين Stemming و Lemmatization؟

إرجاع الكلمة لأصلها: Lemmatization. اختزال الكلمة لجذرها بدون مراعاة المعنى (برمجة→ برمج): Stemming
أبطأ لكن أكثر دقة Lemmatization، أسرع لكن أقل دقة Stemming. مع مراعاة السياق (أكلت→ أكل).

3. ما هو Bag of Words؟ وما عيوبه؟

هو تمثيل النص كمصفوفة تكرار للكلمات. العيوب: 1) فقدان ترتيب الكلمات، 2) التباين العالي (متجهات متفرقة) BoW،
إعطاء وزن كبير للكلمات الشائعة، 4) تجاهل الدلالات (3).

4. اشرح TF-IDF وكيف يعمل.

هو طريقة إحصائية لتقييم أهمية كلمة في TF-IDF (Term Frequency - Inverse Document Frequency)
مستند ضمن مجموعة من المستندات.

أولاً: TF (Term Frequency) - تكرار الكلمة:

• يقيس مدى تكرار الكلمة داخل المستند الواحد.
• الصيغة: TF = (عدد مرات ظهور الكلمة في المستند) / (إجمالي عدد الكلمات في المستند)
• مثال: إذا ظهرت كلمة 'ذكاء' 5 مرات في مستند مكون من 100 كلمة، فإن TF = 5/100 = 0.05

ثانياً: IDF (Inverse Document Frequency) - التكرار العكسي للمستندات:
• يقيس مدى ندرة الكلمة عبر جميع المستندات.
• الصيغة: IDF = log(إجمالي عدد المستندات / عدد المستندات التي تحتوي على الكلمة)
• مثال: إذا كان لدينا 1000 مستند، والكلمة تظهر في 10 مستندات فقط، فإن IDF = log(1000/10) = log(100) = 2

ثالثاً: TF-IDF = TF × IDF

مثال تطبيقي كامل:
لدينا 1000 مستند، كلمة 'الذكاء' تظهر في 50 مستند، وفي مستند معين ظهرت 10 مرات في مستند مكون من 200 كلمة.
• TF = 10/200 = 0.05
• IDF = log(1000/50) = log(20) ≈ 1.30 (للأساس 10)
• TF-IDF = 0.05 × 1.30 = 0.065

الفكرة الأساسية:
الكلمات المهمة هي التي تظهر بكثرة في مستند واحد (مرتفع TF) ولكنها نادرة في باقي المستندات (مرتفع IDF).

الاستخدامات:
• استخراج الكلمات المفتاحية من المستندات
• تحسين نتائج محركات البحث
• تمثيل النصوص في مهام التصنيف والتجميع

5. ما هي Word Embeddings؟

هي تمثيلات رقمية كثيفة للكلمات في فضاء متعدد الأبعاد، بحيث تكون الكلمات المتشابهة في المعنى قريبة من بعضها. تلتقط العلاقات الدلالية والنحوية، وتستخدم في معظم تطبيقات NLP الحديثة.

6. ما الفرق بين Word2Vec و GloVe؟

▸ Word2Vec (Google, 2013):
• نوع النموذج: تنبؤي (Predictive)
• طريقة التعلم: شبكة عصبية بسيطة
• الاستراتيجيات: CBOW و Skip-gram
• السياق: محلي (نافذة من الكلمات)
• الميزة: يعمل جيدا مع البيانات الكبيرة
• العيب: لا يستخدم الإحصائيات العالمية

▸ GloVe (Stanford, 2014):
• نوع النموذج: قائم على الإحصاءات (Count-based)
• طريقة التعلم: تحليل مصفوفة التكرار المشترك

السياق :عالمي)المجموعة الكاملة من النصوص(•
الميزة :يجمع بين النماذج الإحصائية والتنبؤية •
العيب :يحتاج لبناء مصفوفة التكرار المشترك •

7. ما هي التحديات في اللغة العربية؟

الاختلاف الكبير في اللهجات حتى في نفس اللغة

التشكيل :تغير المعنى بتغير الحركات .

الاشتقاق :تنوع الكلمات من جذر واحد .

الفرق بين الفصحى والعامية .

ندرة البيانات مقارنة بالانجليزية .
6. الكتابة من اليمين لليسار (RTL)
7. الوصل والفصل في الكتابة

8. اشرح مفهوم Language Modeling.

.هو نموذج يحسب احتمالية تسلسل الكلمات ويتنبأ بالكلمة التالية Language Model

▸ أنواع نماذج اللغة:
• Autoregressive (GPT): يتنبأ بالكلمة التالية - اتجاه واحد
• Masked Language Model (BERT): يتنبأ بالكلمات المحذوفة - اتجاهين

▸ التطبيقات:
• الترجمة الآلية
• التلخيص التلقائي
• توليد النصوص
• الإجابة عن الأسئلة

9. ما هو Attention Mechanism؟

آلية تسمح للنموذج بالتركيز على الكلمات الأكثر أهمية في السياق .تحسب أوزان الانتباه لكل كلمة، ثم تجمع المتجهات بشكل مرجح .تحل مشكلة الاعتماد طويل المدى وتحسن جودة الترجمة.

▸ أنواع الانتباه:
• Self-Attention: داخل نفس التسلسل
• Cross-Attention: بين الإدخال والإخراج
• Multi-Head Attention: عدة رؤوس تعمل بالتوازي

▸ المزايا:
• تحل مشكلة الاعتماد طويل المدى
• تسمح بالنظر لجميع الكلمات معا
• تحسن جودة الترجمة والتلخيص

10. ما الفرق بين RNN و Transformer؟

- RNN (Recurrent Neural Network):
  - تعالج التسلسل خطوة بخطوة)متسلسلة(
  - تعاني من مشكلة تلاشي التدرج
  - بطيئة في التدريب)لا يمكن توازي المعالجة(
  - صعوبة في السياقات الطويلة

- Transformer:
  - تعالج التسلسل بالكامل بالتوازي
  - تستخدم Self-Attention
  - أسرع في التدريب
  - أكثر قدرة على فهم السياقات الطويلة
  - GPT و BERT أساس نماذج

11. ما هو NER؟ مع مثال

NER (Named Entity Recognition) هو تحديد الكيانات المسماة في النص. مثال: 'أحمد يعمل في جوجل في مصر' → [أحمد: شخص]، [جوجل: منظمة]، [مصر: مكان].

12. اشرح POS Tagging.

POS Tagging هو تحديد الفئة النحوية لكل كلمة اسم، فعل، صفة، حرف جر يساعد في فهم البنية النحوية وتحسين الترجمة والتحليل الدلالي.

13. ما هو Sentiment Analysis؟

تحليل المشاعر هو تصنيف النص إلى إيجابي، سلبي، أو محايد. يستخدم في تحليل آراء العملاء ورصد المشاعر على وسائل التواصل الاجتماعي.

Sentiment Analysis هو تحليل المشاعر وتصنيف النص إلى إيجابي أو سلبي أو محايد.

- الأنواع:
  - ثنائي: إيجابي / سلبي
  - ثلاثي: إيجابي / سلبي / محايد
  - متعدد: درجات 1-5

- التطبيقات:
  - تحليل آراء العملاء
  - رصد المشاعر على وسائل التواصل

14. ما هو Overfitting وكيف تعالجه؟

هو عندما يحفظ النموذج البيانات بدلا من تعلم الأنماط.

- الحلول:

1. Dropout: تعطيل عشوائي للخلايا
2. Data Augmentation: زيادة البيانات
3. Early Stopping: إيقاف التدريب المبكر
4. Regularization: L1/L2 Regularization
5. تبسيط النموذج: تقليل عدد الطبقات

15. ما الفرق بين Supervised و Unsupervised في NLP؟

- Supervised Learning (تحت الإشراف):
  - يتطلب بيانات مُعلّمة
  - أمثلة: تصنيف النصوص، NER
  - الميزة: دقة عالية
  - العيب: يحتاج وقت لتصنيف البيانات

- Unsupervised Learning (غير تحت الإشراف):
  - يتعلم من بيانات غير مُعلّمة
  - أمثلة: Clustering، Word Embeddings
  - الميزة: لا يحتاج بيانات مصنفة
  - العيب: صعوبة تقييم النتائج

القسم الثالث: أسئلة عملية وتحليلية (15 سؤال) 💻

1. قم بعمل Tokenization للجملة: 'الذكاء الاصطناعي يغير العالم'

النتيجة: ['الذكاء', 'الاصطناعي', 'يغير', 'العالم']

2. احذف Stop Words من الجملة: 'أنا أريد أن أتعلم معالجة اللغات الطبيعية'

بعد الحذف: ['أريد', 'أتعلم', 'معالجة', 'اللغات', 'الطبيعية']

3. احسب: IDF إذا ظهرت كلمة في 50 مستند من أصل 1000 تقريباً

IDF = log(1000/50) = log(20) ≈ 1.30 (للأساس e) (أو 3.0 للأساس 10)

4. احسب Cosine Similarity بين متجهين بسيطين

A=[1,2,0] ، B=[0,2,1] ، التشابه =0.8

5. لديك بيانات نصية: كيف تحوّلها إلى أرقام؟

الطرق: CountVectorizer، TF-IDF، Word Embeddings (Word2Vec/GloVe)، Subword Tokenization.

6. صمّم Pipeline لمعالجة النصوص

1- جمع البيانات، 2- تنظيف، 3- تطبيع، 4- Tokenization، 5- Vectorization، 6- نشر، 7- تقييم، 8- تدريب.

لديك بيانات صغيرة أي نموذج تستجدمة ولماذا

Naive Bayes أو Logistic Regression. السبب: مقاومة Overfitting وتدريب سريع.

لديك بيانات كبيرة أي نموذج تستخدمة ولماذا

BERT أو GPT. السبب: قدرة عالية على تعلم السياقات المعقدة.

9. كيف تحسن دقة نموذج تصنيف نصوص؟

تحسين البيانات، استخدام Embeddings، الانتقال لنماذج أقوى، ضبط المعايير.

10. كيف تتعامل مع النصوص العربية؟

تطبيع النصوص، استخدام AraBERT، إزالة التشكيل، استخدام Farasa للتقطيع.

11. صمّم نظام Sentiment Analysis

AraBERT + طبقة تصنيف + Fine-tuning على بيانات المراجعات.

12. لديك مشكلة Overfitting: اقترح 3 حلول

1- Dropout، 2- Data Augmentation، 3- Early Stopping.

13. قارن بين Logistic Regression و Naive Bayes

LR: أكثر دقة، لا يفترض استقلالية السمات. NB: سريع، افتراضات قوية.

14. لديك نصوص غير نظيفة: كيف تنظفها؟

إزالة HTML، توحيد المسافات، التطبيع، إزالة التشكيل، الروابط، الرموز.

15. صمّم مشروع NLP كامل

جمع بيانات، تنظيف، تدريب: تصنيف شكاوى العملاء، AraBERT، نشر API، مراقبة الأداء.

القسم الرابع: مفاهيم متقدمة

- **BPE:**

Byte Pair Encoding - طريقة Subword Tokenization لتجزئة الكلمات النادرة.

- **Subword Tokenization:**

وتقليل حجم المفردات (OOV) التعامل مع الكلمات خارج المفردات.

- **n-gram:**

تسلسل من n كلمات متتالية (Unigram=1, Bigram=2, Trigram=3).

- **Perplexity:**

قياس جودة النموذج اللغوي (كلما قلّ كان أفضل).

- **BLEU:**

مقياس لتقييم الترجمة الآلية (يركز على الدقة).

- **ROUGE:**

مقياس لتقييم التلخيص (يركز على الاستدعاء).

- **Seq2Seq:**

نموذج Encoder-Decoder يستخدم في الترجمة والتلخيص.

- **Self-Attention:**

يربط كل كلمة بباقي الكلمات لحساب الأهمية النسبية.

- **Fine-tuning:**

تحسين نموذج مدرب مسبقاً على مهمة محددة.

- **Transfer Learning:**

. Zero-shot Learning:

- الإجابة الصحيحة: ب (بدون تدريب مباشر

. Few-shot Learning:

- الإجابة الصحيحة: ب (بيانات قليلة

القسم الخامس: أسئلة نظرية متقدمة (15 سؤال) ✍

1. اشرح Subword Tokenization ولماذا هي مهمة.

هي طريقة تقوم بتقسيم الكلمات النادرة إلى وحدات أصغر متكررة. مثال: 'الذكاء' → ['ذكاء', '-'] Subword Tokenization

أهميتها:

- تحل مشكلة الكلمات خارج المفردات (Out-of-Vocabulary)

- تقلل حجم المفردات بشكل كبير
- تساعد النماذج على فهم البنى الداخلية للكلمات
- تتعامل مع الكلمات الجديدة والمشتقات

أمثلة: BPE، WordPiece، Unigram

2. ما الفرق بين Autoregressive Models و Masked Language Models؟

- Autoregressive Models (مثل GPT):
  - تتوقع الكلمة التالية بناءً على الكلمات السابقة فقط
  - اتجاه واحد (من اليسار إلى اليمين)
  - تستخدم في مهام التوليد (كتابة النصوص، الترجمة)
  - مثال: GPT، LLaMA

- Masked Language Models (مثل BERT):
  - تخفي نسبة من الكلمات وتتوقعها بناءً على السياق المحيط
  - اتجاهين (يسار ويمين)
  - تستخدم في مهام الفهم (التصنيف، NER)
  - مثال: BERT، RoBERTa

3. اشرح مفهوم Perplexity وكيف يتم استخدامه.

Perplexity هو مقياس لتقييم جودة نماذج اللغة.

- المعنى: يقيس مدى حيرة النموذج عند رؤية بيانات جديدة.
- التفسير: كلما كانت القيمة أقل، كان النموذج أفضل في توقع البيانات.

- مثال:
  - نموذج جيد: Perplexity = 20
  - نموذج ضعيف: Perplexity = 200

4. ما الفرق بين ROUGE و BLEU بالتفصيل؟

- BLEU (Bilingual Evaluation Understudy):
  - يستخدم في تقييم الترجمة الآلية
  - يركز على الدقة (Precision)
  - يقيس عدد n-grams في النص المنتج التي تظهر في النص المرجعي

- ROUGE (Recall-Oriented Understudy):
  - يستخدم في تقييم التلخيص
  - يركز على الاستدعاء (Recall)
  - يقيس عدد n-grams في النص المرجعي التي تظهر في النص المنتج

5. اشرح بنية Transformer بالتفصيل.

- Encoder (الجهة اليسرى):
  - يتكون من N طبقات متطابقة

• كل طبقة تحتوي على:
- Multi-Head Self-Attention
- Feed-Forward Network
- Add & Norm

▸ Decoder (الجهة اليمنى):
• يتكون من N طبقات متطابقة
• كل طبقة تحتوي على:
- Masked Multi-Head Self-Attention
- Cross-Attention
- Feed-Forward Network
- Add & Norm

6. ما هو Self-Attention وكيف يعمل؟

هي آلية تربط كل كلمة بباقي الكلمات في الجملة لحساب الأهمية النسبية. Self-Attention

▸ طريقة العمل:
1. تحويل كل كلمة إلى 3 متجهات: Query (Q)، Key (K)، Value (V)
2. حساب درجة الانتباه: Q × K^T
3. تطبيق Softmax للحصول على الأوزان
4. ضرب الأوزان في V للحصول على الناتج

7. ما هي Positional Encoding ولماذا نحتاجها؟

هي متجهات تضاف إلى Positional Encoding Embeddings لتزويد النموذج بمعلومات عن موقع الكلمة. الكلمات

▸ لماذا نحتاجها؟
• لأن Self-Attention لا تحتوي على مفهوم الترتيب
• بدونها، الجملة 'أكل الولد التفاحة' و 'أكل التفاحة الولد' ستكونان متماثلتين

8. اشرح الفرق بين Encoder و Decoder في Transformer.

▸ Encoder:
• يقرأ النص المدخل بالكامل (ثنائي الاتجاه)
• ينتج تمثيلاً سياقياً غنياً
• يستخدم في مهام الفهم (BERT)

▸ Decoder:
• يولد النص كلمة بكلمة (أحادي الاتجاه)
• يستخدم Masked Self-Attention
• يستخدم في مهام التوليد (GPT)

9. ما هو Fine-tuning ولماذا هو مهم؟

هو عملية أخذ نموذج مدرب مسبقاً ومواصلة تدريبه على مهمة محددة. Fine-tuning

- أهميته:
- يوفر وقتاً وتكلفة التدريب
- يحقق أداءً عالياً مع بيانات قليلة
- ينقل المعرفة اللغوية العامة لمهام محددة

10. ما هو Transfer Learning في NLP؟

هو استخدام المعرفة من نموذج مدرب على مهمة ما لحل مهمة أخرى Transfer Learning.

- مراحل Transfer Learning:
1. Pre-training: تدريب على بيانات ضخمة
2. Fine-tuning: تكييف على مهمة محددة

11. ما هو Zero-shot Learning؟ مع مثال

هي قدرة النموذج على أداء مهمة لم يتدرب عليها مباشرة Zero-shot Learning.

- مثال:
النموذج لم يتدرب على تصنيف النصوص الطبية.
'التعليم' :صنف النص إلى :عرض مرضي أو موعد
'النص' :أعاني من صداع
النتيجة :عرض مرضي

12. ما الفرق بين GPT و BERT؟

- GPT:
- الهندسة: Decoder-only
- الاتجاه :أحادي الاتجاه
- المهام :التوليد)الكتابة، الترجمة(

- BERT:
- الهندسة: Encoder-only
- الاتجاه :ثنائي الاتجاه
- المهام :الفهم (التصنيف، NER)

13. اشرح Seq2Seq Model مع مثال.

هو نموذج يتكون من Seq2Seq Encoder و Decoder لتحويل تسلسل إلى تسلسل.

- مثال :الترجمة الآلية
الإدخال: 'I love you'
Encoder: يحولها إلى متجه
Decoder: 'يولد 'أنا' ← 'أحب' ← 'ك

14. ما هي التحديات في بناء Chatbot؟

1. فهم النية :تحديد ما يريده المستخدم
2. إدارة الحوار :الحفاظ على سياق المحادثة

الاتساق :عدم التناقض في الإجابات 3.
الشخصية :منح الروبوت شخصية ثابتة 4.
التعامل مع الحالات غير المتوقعة 5.
اللغة الطبيعية :التعامل مع العامية 6.
تعدد اللغات 7.

15. كيف تقيم نموذج NLP؟ (metrics)

- التصنيف: Accuracy, Precision, Recall, F1-Score
- الترجمة: BLEU, METEOR
- التلخيص: ROUGE
- نماذج اللغة: Perplexity
- الإجابة عن الأسئلة: Exact Match, F1

القسم السادس :أسئلة عملية /تصميم أنظمة)15 سؤال(💻

1. لديك نص طويل :كيف تقوم بتلخيصه باستخدام NLP؟

طريقتان: Extractive (TextRank, BERTSUM) و Abstractive (T5, BART).

2. صمّم نظام ترجمة آلية بسيط.

استخدام HuggingFace transformers مع نموذج مثل Helsinki-NLP/opus-mt-en-ar.

3. لديك بيانات متعددة اللغات :كيف تتعامل معها؟

أو اكتشاف اللغة وتوجيهها لنماذج متخصصة، XLM-Roberta أو mBERT استخدام.

4. كيف تبني Chatbot ذكي؟

Retrieval-based (FAISS + Sentence Transformers) أو Generative (GPT fine-tuning).

5. لديك مشكلة Ambiguity في النص :كيف تعالجها؟

Word Sense Disambiguation. و Coreference Resolution، للسياق BERT استخدام

6. كيف تتعامل مع Out-of-Vocabulary words؟

استخدام Subword Tokenization (BPE, WordPiece) أو FastText.

7. لديك Dataset غير متوازن :كيف تعالجه؟

SMOTE, class weights, focal loss, أو جمع بيانات إضافية.

8. كيف تبني نظام NER باستخدام Deep Learning؟

NER. على بيانات Fine-tuning مع BERT + طبقة تصنيف + CRF،

9. كيف تستخدم Transformer في مشروعك؟

اختيار نموذج مناسب، Fine-tuning، تصدير ONNX، وإنشاء API.

10. كيف تختار بين BERT و GPT حسب المهمة؟

BERT للفهم (تصنيف، NER)، GPT (للتوليد)كتابة، ترجمة.

11. لديك نصوص noisy: كيف تنظفها؟ (advanced level)

إزالة HTML، تصحيح إملائي باستخدام تطبيع عربي، إزالة تشكيل، Farasa.

12. كيف تحسن سرعة inference لنموذج NLP؟

Quantization, pruning, distillation, ONNX, TensorRT.

13. صمّم نظام Question Answering.

Extractive QA (BERT) أو Generative QA (T5) مع Fine-tuning.

14. كيف تبني نظام Text Summarization؟

استخدام PEGASUS أو BART مع Fine-tuning على بيانات التلخيص.

15. صمّم نظام NLP)مثلاً بنك أو خدمة عملاء(متكامل لشركة

نظام مراقبة API لاستخراج المعلومات، مع NER، Chatbot، تحليل المشاعر، تصنيف الشكاوى.

نقل المعرفة من نموذج مدرب على بيانات ضخمة لمهام أخرى.